

基于多源域迁移学习与 Xgboost 的中国死亡率预测

摘要

死亡率预测是人口统计学和保险精算学领域的重要研究课题，并在社会医疗资源配置、养老金测算、长寿风险管理等领域具备较为重要的应用价值。但对于部分地区，如中国，由于死亡率数据量较少，且数据质量有限，传统统计模型与机器学习方法出现拟合或泛化能力弱化等问题。本研究针对中国死亡率历史数据有限的问题，提出一种基于多源域迁移学习与 XGBoost 方法结合的死亡率预测框架。通过整合亚洲五国（日本、韩国、新加坡、越南、哈萨克斯坦）的死亡率数据及保险密度、医疗资源等六项特征指标，利用 XGBoost 构建特征-输出映射关系，并引入 SHAP（Shapley Additive Explanations）值分布相似性量化源域与目标域的可迁移性。通过计算最大均值差异筛选与目标域特征贡献模式高度相似的源域，结合动态加权集成算法优化模型权重，实现多源域知识迁移。

实证结果表明，该框架显著地提升了数据稀缺场景下的预测精度。对于中国死亡率数据，测试集的平均绝对误差为 0.0037，且 SHAP 值分析揭示了“人均医疗床位”“保险覆盖率”等特征因子的非线性影响路径，增强了模型可解释性。此外，迁移学习集成结果显示，日本、新加坡等源域模型权重较高（分别为 1.94 和 0.93），验证了特征贡献模式对齐的有效性。

本研究创新性地通过构建特征-输出映射，采用 SHAP 值分布相似性量化源域与目标域可迁移性的方法，将可解释迁移学习方法引入死亡率预测问题，一定程度上解决了传统方法依赖形态相似性导致的负迁移风险，为数据不足地区构建数据驱动型健康治理体系提供了兼具精度与可解释性的解决方案。

关键词：多源域迁移学习；死亡率预测；SHAP 值；XGBoost

目录

摘要.....	I
表格与插图清单.....	IV
一、研究背景与描述.....	5
（一）研究背景.....	5
（二）分析方法选取.....	6
二、文献综述.....	7
（一）国内外研究现状.....	7
1. 动态死亡率模型的发展改进与应用.....	7
2. 机器学习在死亡率预测中的应用.....	8
3. 迁移学习的跨域适应性在死亡率预测中的可行性.....	9
（二）文献评述.....	9
（三）本文贡献.....	10
三、数据描述与处理.....	11
（一）数据收集.....	11
（二）指标选取.....	12
（三）数据质量说明.....	12
四、模型建立与分析.....	13
（一）建模思路.....	13
（二）XGBoost 算法原理.....	13
1. 原理介绍.....	13
2. 模型建立.....	15
3. 模型优化.....	17
（三）XGBoost 模型预测的结果解释——基于 SHAP 模型.....	20
1. 原理介绍.....	20
2. 特征重要性解释.....	21
3. 模型相似性度量.....	23
（四）多人口死亡率迁移学习.....	25

1. 迁移学习原理.....	25
2. 迁移学习集成框架.....	25
五、结论.....	28
参考文献.....	30
附录.....	34

表格与插图清单

表 1	指标含义及来源.....	11
表 2	基准模型评估结果.....	16
表 3	优化后模型的评估结果.....	18
表 4	特征相似性结果.....	24
表 5	源域权重分配结果.....	26
表 6	各模型预测性能对比图.....	27
图 1	XGBoost 数据处理过程示意图.....	14
图 2	基准模型预测回归线组图.....	17
图 3	优化后模型的实际值和预测值.....	19
图 4	优化后模型的残差图.....	20
图 5	各国人口死亡率 SHAP 蜂群组图.....	22
图 6	各国 SHAP 模型特征重要性热图.....	23
图 7	源域模型权重示意图.....	27
图 8	中国人口死亡率预测值与实际值绝对误差结果图.....	28

基于多源域迁移学习与 Xgboost 的中国死亡率预测

一、研究背景与描述

（一）研究背景

死亡率作为衡量国家公共卫生水平与经济社会发展的重要指标，其精准预测对优化医疗资源配置、完善社会保障体系及制定科学人口政策具有深远意义。随着全球老龄化进程加速，各国政府愈发重视死亡率数据的动态监测与趋势分析。世界卫生组织（World Health Organization, WHO）指出，死亡率预测不仅是评估医疗系统效能的核心依据，更是实现联合国可持续发展目标（Sustainable Development Goals, SDGs）中“健康与福祉”目标的关键支撑[17]。然而，受限于数据收集成本、统计标准差异及隐私保护政策等因素，许多地区尤其是发展中国家常面临历史死亡率数据稀缺的挑战，传统统计模型与机器学习方法在此类场景下易因样本不足导致过拟合或泛化能力弱化，在一定程度上制约预测精度[28]。

2020 年，我国 65 岁及以上人口比重已达到 13.50%，老年人口规模庞大[1]。与人口老龄化相伴的还有人口长寿趋势。由于经济水平提升、生活条件改善、医疗水平进步等原因，2023 年，我国居民人均预期寿命达到 78.6 岁[2]，因此可能给养老与健康保障体系带来诸多问题。死亡率预测是养老金成本与债务评估、长寿风险度量与管理的基础和核心[3]，在一定程度上对国家医疗战略布局、养老金收支核算等有重要意义。

对死亡率模型的研究近几十年来已有较多成果。从单一刻画死亡率随年龄变动的静态死亡率模型（例如 Gompertz-Makeham Law），到包含年龄和时间因素的各类动态模型（例如 Lee-Carter 模型族），再到机器学习方法，死亡率模型的研究不断丰富，死亡率预测的方法更加多元。在死亡率建模与预测中，为更好地捕捉数据的变化趋势，提升参数预测精度，一般需要较长期的时间序列数据。而中国大陆地区死亡率数据相对较少，数据波动性在非普查与 1%抽查年中相对较大，直接应用现有预测模型存在一定的准确性问题[3]。

对于单一国家或地区死亡率建模和多人口死亡率建模，现有研究均较为丰富。但之前研究中对多人口死亡率建模，多是在原有单人口统计模型上的拓展。对于

某些特征因素如何影响死亡率，在多大程度上影响死亡率，研究相对较少。与此同时，中国周边国家（如日本、韩国等）在人口结构、医疗资源配置及社会保障政策方面与中国存在一定的相似性与差异性，其丰富的死亡率数据为跨域知识迁移提供了潜在价值。在本文中，跨域指的是跨地区，即一般研究中常提的多人口；跨域数据（多源域数据）指的是多地区人口死亡率及相关特征数据。如何有效利用多源域数据，突破“数据孤岛”限制，成为提升中国死亡率预测能力的重要突破口。

尽管迁移学习在医疗影像诊断[18]、流行病预测[19]等领域展现了优秀的跨域适应能力，但其在死亡率预测中的应用仍处于探索阶段。传统迁移学习方法多依赖数据形态相似性（如曲线波动模式）筛选源域，未能深入挖掘特征-输出映射关系的本质关联，易导致负迁移风险[20]。例如，尽管日本与中国老龄化趋势相似，但其高人均医疗资源覆盖率可能使得相同特征（如医师数量）对死亡率的影响机制存在差异。因此，构建可量化评估域间特征贡献相似性的迁移学习框架，成为提升跨域预测稳健性的关键。

本研究提出“基于多源域迁移学习与 XGBoost 的中国死亡率预测”方法，首次将可解释机器学习与多源迁移学习结合，旨在解决贫资料地区死亡率预测难题。通过引入 SHAP（Shapley Additive Explanations）值量化可能影响死亡率的特征对死亡率贡献的分布差异，筛选与目标域国家（中国）映射关系高度相似的源域国家（如日本、韩国、越南等），并集成多源域知识优化模型性能。这一方法考虑了跨域数据间的关联性与互补性，并在一定程度上分析了特征因素对死亡率的影响程度。这一方法基于多人口数据特征，为有效数据不足情况下的死亡率预测提供了新思路，同时可为其他贫资料国家或地区死亡率预测提供技术参考。

（二）分析方法选取

本研究尝试通过多地区人口死亡率数据对单目标地区人口死亡率进行预测，但直接就多人口死亡率数据进行时间序列数据特征识别与迁移，存在偶然性和难解释性。其他地区死亡率数据与目标地区死亡率数据相近并不意味着影响其死亡率的因素相似。本研究构造了一种基于多源域死亡率与特征指标对目标域死亡率进行建模预测的方法，分析特征与死亡率之间的作用机制，利用 XGBoost 构建目标域和源域间的特征-输出映射关系，选择源域中与目标域相似的特征，基于 SHAP

值量化其特征-输出映射关系的相似性，最后依据相似性优化各源域模型权重，完成目标域死亡率预测。

二、文献综述

（一）国内外研究现状

死亡率预测作为人口学、保险精算和公共卫生领域的重要课题，其方法经历了从传统统计模型到机器学习的迭代发展。以下主要从动态死亡率模型的改进、机器学习在死亡率预测中的应用以及迁移学习的跨域适应性三方面展开综述。

1. 动态死亡率模型的发展改进与应用

动态死亡率模型的核心在于捕捉死亡率随时间、年龄及协变量的演化规律。Lee-Carter 模型作为经典方法，通过年龄因子与时间趋势的线性组合刻画死亡率变化，但其对非线性时序特征的适应性不足[21]。王晓军等（2020）[4]的综述文章较完整、系统地梳理了截至 2020 年动态死亡率模型的研究进展。在 Lee-Carter 经典模型的基础上，学界提出了多项改进。陶祥兴等（2022）将 ARIMA 与 LSTM 结合，构建 ARIMA-LSTM 混合模型，在中国香港男性死亡率数据中验证了其短期预测优势[5]。段白鸽（2019）在动态模型中引入极值理论（EVT）和分层建模技术，覆盖低龄、高龄及超高龄全年龄段，揭示中国死亡率动态演变规律，并量化长寿风险对保险产品定价的影响[6]。针对中国数据稀缺问题，王晓军团队（2020）采用贝叶斯模型平均（BMA）方法，量化模型不确定性，缓解参数估计偏差，在有限数据下实现高精度预测[3]。杨刚等（2023）提出基于 AE-LSTM 的高龄人口死亡率预测模型，通过自编码器提取特征，LSTM 捕捉时序依赖性，显著降低了预测误差[7]。此外，分数布朗运动驱动的 $0-U$ 过程也被用于改进 Lee-Carter 模型的时间参数拟合，进一步提升了长期预测的稳健性[5]。

国际研究则聚焦多源数据整合与复杂风险建模。在死亡率改善因子研究中，Plat（2011）将对数死亡率进行差分后得到死亡率递减因子[29]。Michel Denuit 等（2022）在 Lee-Carter 框架中引入 Wang 变换，量化长寿风险证券化定价问题，为风险管理提供新工具[22]。在多人口死亡率模型方面，Jevtic 等（2023）构建了广义线性模型混合 Levy 过程的多人口死亡率建模框架[30]。Chen 等（2015）采用 Copula 死亡率模型与最大熵方法分析多人口死亡率[31]。Ka Kin Lam 和 Bo

Wang 提出加权多变量函数型数据主成分分析方法对多人口死亡率建模，其效果优于传统模型[32]。Matteo (2024) 在多人口死亡率预测中考虑了经济、环境和生活方式等因素，强调死亡率与更广泛的社会经济和环境因素的相互关联性[34]。

这些研究表明，动态死亡率模型的改进路径正从单一统计模型转向“模型+机器学习”的混合范式，兼顾可解释性与非线性关系挖掘能力，死亡率预测方法呈现多样化发展趋势。

2. 机器学习在死亡率预测中的应用

机器学习凭借其强大的非线性拟合能力，逐步成为死亡率预测的主流工具。在模型选择上，LSTM 因其对时序特征的捕捉能力被广泛应用。肖鸿民等 (2021) 基于 Keras 框架构建 LSTM 网络，预测中国台湾省死亡率，结果显示其 RMSE 较传统模型降低 30%，验证了深度学习对长记忆性数据的适应性[8]。XGBoost 则在小样本场景中表现突出，如四川大学团队 (2025) 提出的 CRISP 模型结合 XGBoost 与因果推断，在 ICU 患者死亡率预测中 AUROC 达 0.948，显著优于传统评分系统[23]。此外，集成学习方法（如 Stacking）通过融合多模型优势，提升了预测精度。于宏佳 (2022) 采用 Stacking 方法集成 ARIMA、LSTM 和 XGBoost，在中国人口死亡率预测中实现更高鲁棒性，误差降低 15%[9]。在死亡率异质性建模方面，李芳芳 (2023) 基于模糊聚类与 Bi-GRU 构建多人口死亡率模型，通过聚类划分群体特征后分别建模，有效降低了跨群体预测误差[10]。

在多人口死亡率预测中，机器学习方法同样发挥作用。Perla 等 (2022) 用神经网络构建考虑局部连贯性的多人口死亡率预测模型，模型使得死亡率预测更精确，需要优化的参数更少[33]。

机器学习方法的可解释性逐渐提升。赵明与王晓军 (2023) 提出混合泊松模型 (Mixed Poisson Model)，结合中国人口死亡风险异质性特征，通过 XGBoost 筛选关键协变量（如城乡差异、教育水平），提升长寿风险度量的精准性[11]。Qiao 等 (2024) 采用多国数据融合框架，提出基于邻近预测、模型集成与树提升的机器学习框架，整合人类死亡率数据库 (HMD) 中多国数据，显著降低 20 年死亡率预测的 MAPE（平均绝对百分比误差）达 50%，验证了跨域数据对长期趋势建模的增益效应[24]。

3. 迁移学习的跨域适应性在死亡率预测中的可行性

迁移学习通过跨领域知识迁移,为解决数据稀缺和分布差异问题提供了创新路径。但迁移学习应用场景更集中在图像识别、自然语言处理方面,对跨域数据之间内在关系的识别与迁移相关研究较少。例如,在流行病预测方面,Reham Abdallah 团队利用东南亚登革热数据预训练 LSTM 模型,迁移至拉美地区预测寨卡病毒传播风险[25]。

现阶段,迁移学习在死亡率预测和保险精算上的研究相对较少。李昆骅(2014)基于 CBD 模型构建多国死亡率联合框架,通过英国与加拿大数据验证跨国相关性对债券定价的影响,证明迁移学习可降低长寿风险对冲成本[12]。Asmik Nalmpatian 等(2023)以英国为源域,通过迁移学习预测其他国家的死亡率,验证了跨域知识迁移的可行性[26]。Michel Denuit et al(2022)开发跨域死亡率衍生品,利用东南亚国家数据预训练模型,迁移至欧洲市场定价长寿债券,误差率较单域模型降低 9%[22]。迁移学习方法在跨域数据特征识别与预测上的研究仍有待深入。

本文在一定程度上参考了唐義坤等(2025)在电力负荷预测中的方法,借鉴电力负荷预测中的 SHAP 值分布相似性(SSVD)[13],可度量不同国家死亡率数据的特征-输出映射一致性;基于 XGBoost 优化权重的正则化加权集成算法可迁移至死亡率预测。迁移学习在死亡率预测中的可行性体现在特征贡献模式对齐与多源互补性增强,其方法论框架(如 SHAP 值量化、动态集成)已在电力领域得到验证,具备跨域扩展潜力。

(二) 文献评述

动态死亡率模型的研究历经数十年发展,从经典 Lee-Carter 模型到混合机器学习框架,逐步提升了对复杂死亡率模式的捕捉能力。Lee 和 Carter(1992)提出的基础模型通过年龄因子与时间趋势的线性组合刻画死亡率演变,但其对非线性时序特征(如突发公共卫生事件导致的死亡率骤变)的适应性不足,且在数据稀缺场景下参数估计易出现偏差。

传统模型(如 Lee-Carter、CBD 模型)由于线性假设限制,较难捕捉突发事件导致的死亡率非线性波动[14]。贝叶斯方法虽缓解了小样本问题,但对先验分布的选择敏感,可能导致结果主观性偏差[15]。

机器学习在死亡率预测中的应用已从单一模型向多模态融合与可解释性增强方向深化。但现阶段机器学习方法仍存在黑箱问题，模型信任度较低，多数研究（如 LSTM 预测）依赖复杂网络结构，导致保险精算师与政策制定者难以理解模型逻辑[8]。

迁移学习通过跨域知识迁移，为数据稀缺场景提供了突破路径。唐義坤等（2025）在电力负荷预测中提出的 XGBoost-SHAP 框架，通过计算 SHAP 值分布相似性（SSVD），筛选有效源域并动态集成多源模型，预测误差降低 10%以上[13]。但迁移学习在死亡率预测中的应用目前较少，且迁移学习的现有方法多依赖形态相似性（如曲线波动）筛选源域，忽略特征贡献机制差异。例如，日本与中国老龄化趋势相似，但医疗资源分布差异可能导致相同特征（如医师数量）的影响权重不同，直接迁移易引发偏差[26]。

总体而言，当前研究在动态模型优化与机器学习应用上取得显著进展，但模型可解释性、长期预测稳定性及跨域适应性仍是核心瓶颈。迁移学习通过特征贡献模式对齐与多源动态集成，为死亡率预测提供了新路径，但其在保险精算与公共卫生领域的落地仍需解决负迁移风险与异构数据融合难题。未来研究需进一步结合因果推断与元学习框架，构建兼具精度、可解释性与泛化能力的预测方法。

（三）本文贡献

针对现有研究在死亡率预测中面临的数据稀缺性、模型可解释性不足及跨域适应性薄弱等核心问题，本研究提出“基于多源域迁移学习与 XGBoost 的中国死亡率预测”框架，首次将电力负荷预测领域的可解释迁移学习方法引入人口健康领域。通过设计基于 SHAP 值分布相似性（SSVD）的量化指标，精准筛选与目标域特征贡献模式高度一致的源域，突破传统方法依赖形态相似性导致的负迁移风险；进一步结合动态加权集成算法，优化多源域知识组合权重，在有限目标数据下实现预测误差降低。同时，通过 XGBoost 内置特征重要性分析与 SHAP 局部可解释性工具，揭示“人均医疗床位”“保险覆盖率”等关键因子的非线性贡献路径，为政策制定者提供透明决策依据。该框架能够在死亡率预测过程中，同时分析影响死亡率的相关因素，能够分析相关因素对死亡率的影响贡献，在一定程度上提升了模型的可解释性，为发展中国家构建数据驱动型健康治理体系提供了兼具创新性与实用性的解决方案。

三、数据描述与处理

（一）数据收集

本文以中国为主要研究对象，选取日本、韩国、哈萨克斯坦、越南和新加坡五个国家为参考对象，聚焦于 55 至 85 岁人群的总体死亡率。选取原因主要基于两个方面的考量：一方面，这些国家均为亚洲国家，与中国地理位置接近，在文化、人口结构与发展阶段上具备一定的相似性；另一方面，这些国家在人口老龄化进程与公共健康体系建设方面各具特点，具有较强的可比性与参考价值，能够为中国的相关政策提供借鉴与支持。其中，死亡率数据来源于人类死亡率数据库（Human Mortality Database），经标准化整理，确保年龄段划分一致、时间跨度统一。

对于解释变量，本文收集了六项国家层面特征指标，分别为保险密度（density）、保费收入（income）、保险深度（depth）、人均医疗支出（healthcare）、每万人拥有的病床数（bed）与每千人中的医生、护士和助产士数量（staff）。其中，density、income 与 depth 数据来源于 Wind 数据库，healthcare、bed 和 staff 指标从世界银行（The World Bank）获取。为提高数据可比性，我们对所有变量进行了单位统一与归一化处理，并对缺失值采用线性插值法进行补全。在数据清洗过程中，本文进一步剔除了异常值与结构性缺失数据，确保样本在时间维度（按年度）与空间维度（按国家）上的完整性与平衡性。最终形成 2006 至 2022 年包含六国 55-85 岁各年龄组死亡率与六项特征指标的结构化面板数据集，为后续基于 XGBoost 的建模及迁移学习分析提供了高质量的数据基础。

表 1 指标含义及来源

指标名称	指标含义	数据来源
density	保险密度，即人均保费支出水平，反映保险在居民中的普及程度	Wind 数据库
income	保费收入，表示一个国家保险行业的市场规模和发展水平	Wind 数据库
depth	保险深度，即保费收入占 GDP 的比例，衡量保险业与整体经济的关系	Wind 数据库
healthcare	人均医疗支出（以美元计），反映国家对公共健康的投入程度	世界银行（The World Bank）
bed	每万人拥有的病床数，反映医疗资源的基础设施配备情况	世界银行（The World Bank）

续表 1

指标名称	指标含义	数据来源
staff	每千人中的医生、护士和助产士数量，衡量 医疗服务人员的供给水平	世界银行（The World Bank）

（二）指标选取

本文参考了 Nalmpatian 等(2024)关于迁移学习在死亡率预测中的应用[26]，选取了六项具有代表性的国家层面特征指标，作为影响中老年人群死亡风险的关键变量。分别从保险保障水平、医疗资源投入与人口健康服务供给三个维度出发。保险密度与保险深度作为衡量国家保险发展水平的重要指标，反映了居民通过市场机制对健康风险的防范能力。此外，较高的保险渗透率亦表征了整体风险管理体系的成熟程度。保费总收入是国家保险市场活跃度的直接体现，在一定程度上也反映了经济发展水平与居民健康意识。人均医疗支出指标可有效刻画国家层面医疗资源的可获得性与服务水平。病床资源是基础医疗服务能力的重要体现，尤其在慢性病治疗与老年人群照护中发挥关键作用。此外，包括医生、护士与助产士在内的专业人员供给是影响居民健康服务可及性的重要因素。医疗人力资源不足将直接影响诊疗效率与健康管理质量，进而直接影响老年群体的死亡风险。

以上六项指标从经济能力、制度建设到医疗资源保障层面构成了对中老年人群死亡率影响机制的系统刻画，为后续机器学习建模及跨国迁移提供了合理的数据支撑与理论基础。

（三）数据质量说明

为确保建模分析结果的科学性与可靠性，本研究构建了一套完整的数据质量控制体系，从数据来源、处理流程和质量校验三个维度实施严格管控。在数据来源方面，本研究采用国际公认的权威数据库：死亡率数据来源于人类死亡率数据库（Human Mortality Database），该数据库收录了全球主要国家经过严格校验的标准化死亡率数据；其余六项国家层面特征指标（包括保险密度、保费收入、保险深度、人均医疗支出、每万人病床数、每千人医疗人员数）均来自 Wind 金融数据库和世界银行公开数据库，数据源均采用国际通行的统计标准，确保数据的权威性与国际可比性。

在数据处理阶段，本研究实施了系统化的质量控制措施：首先对原始数据进行标准化处理，统一各指标的计算单位；针对部分国家存在的少量数据缺失问题，运用线性插值法进行合理填补，有效降低数据噪声对模型训练的干扰，确保最终数据集的完整性和可靠性。

经过上述严格的质量控制流程，本研究构建的数据集具有高度的准确性和一致性，满足机器学习模型对训练数据的要求，为后续的死亡率预测建模和政策效应分析提供了坚实的数据基础。同时，标准化的数据处理流程也为后续研究的可重复性和可扩展性提供了保障。

四、模型建立与分析

（一）建模思路

本文主要思路是根据多地区人口死亡率及其相关影响因素对中国人口死亡率及其相关影响因素进行建模与预测。通过分析相关因素在其他国家与在中国对死亡率的影响机制差异，选取相似的影响机制，通过多模型整合的方式更好地预测中国的死亡率。

本文对死亡率进行建模预测的过程整体可分为两个阶段：有效源域选择阶段和多源域模型整合阶段。

在有效源域选择阶段中，参照文献[13]，本文构建了一种量化可迁移性的度量方法。首先，选取源域（选取的其他国家）与目标域（中国）的特征，利用 XGBoost 构建目标域（中国）和源域（其他国家）间的特征 - 输出映射关系。然后，设计了一种基于 SHAP 值分布的方法，用以量化目标模型与每个源模型之间的特征 - 输出映射关系的相似性。

在多源域模型集成阶段，采用了一种多源集成算法，该算法通过赋予各个有效源域模型最佳解释权重，构建针对中国死亡率预测任务的更高性能的集成模型。

（二）XGBoost 算法原理

1. 原理介绍

XGBoost (eXtreme Gradient Boosting) 是一种基于梯度提升框架 (Gradient Boosting) 的高效机器学习算法。相较于传统 GBDT (Gradient Boosting Decision Tree) XGBoost 在此基础上进行了多项优化，包括正则化、二阶导数近似、并行

计算等，使其在预测精度和计算效率上均有显著提升，特别适用于结构化数据的建模任务。




图 1 XGBoost 数据处理过程示意图

XGBoost 的核心思想是通过加法模型（Additive Model）和前向分步算法（Forward Stagewise）逐步优化损失函数，其目标函数由两部分组成：

$$L = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{m=1}^M \Omega(f_m) \quad (1)$$

$$\Omega(f_m) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (2)$$

其中 $(y_i, \hat{y}_i)$ 为损失函数，衡量预测值 $\hat{y}_i$ 与真实值 y_i 的差异； $\Omega(f_m)$ 为正则化项，控制模型复杂度（如叶子节点数等），防止过拟合； T 为叶子节点的个数， w 为分配给该叶子节点的权重。

XGBoost 通过二阶泰勒展开近似损失函数，式（1）可以改写为：

$$L^m = \sum_{i=1}^n \left[g_i f_m(x_i) + \frac{1}{2} h_i f_m(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T (w_j^m)^2 \quad (3)$$

通过引入树结构评分（Tree Scoring）来优化分裂点选择，并应用贪心算法对子树进行划分同时记录有效分割点，其增益（Gain）计算如下：

$$Gain = \frac{1}{2} \left[\frac{(\sum_{i \in L} g_i)^2}{\sum_{i \in L} h_i + \lambda} + \frac{(\sum_{i \in R} g_i)^2}{\sum_{i \in R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma \quad (4)$$

其中 g_i 和 h_i 分别为损失函数的一阶和二阶导数； λ 和 γ 为超参数，分别控制权重平滑度和分裂阈值。 λ 作用于叶子节点权重 L2 范数，惩罚过大的权重值； γ 控制树的复杂度，避免生成冗余节点（预剪枝）。

XGBoost 算法通过引入 L1/L2 正则化有效抑制过拟合问题，同时采用特征预排序和缓存优化技术实现高效并行计算，大幅提升训练效率。其独特的缺失值处理机制能够自动学习最优分裂方向，增强了模型对现实数据中常见问题的适应能力。XGBoost 支持自定义损失函数和评估指标，为不同建模任务提供了高度灵活性。在实际应用中，该算法表现出优异的预测精度，在分类、回归等任务上往往优于传统统计模型。通过 gain 和 cover 等指标，XGBoost 能够量化各特征的重要性，为特征工程提供明确指导。算法对异常值和缺失数据具有较强稳健性，能够有效处理现实场景中的噪声数据。此外，借助 SHAP 值等解释性工具，XGBoost 模型不仅能提供准确预测，还能深入分析各特征对预测结果的贡献程度，增强了模型的可解释性。

2. 模型建立

首先，对每一个国家而言，基于 XGBoost 回归算法分别构建基准预测模型，将数据集按 9:1 的比例划分为训练集（train）和测试集（test），并选取年份（Year）、年龄（Age）和六个指标作为输入变量进行建模。六个国家训练模型评估结果如表 2 所示，其对应的预测回归线与真实值的差异如图 2 所示。

从 R^2 指标来看，所有国家在训练集和测试集上均表现出较高的拟合优度，说明模型能够很好地解释因变量的变化。其中，新加坡（train: 0.9997, test: 0.9973）、日本（train: 0.999, test: 0.9969）和韩国（train: 0.9994, test: 0.9934）的 R^2 值均接近 1，表明模型几乎完全拟合了数据，泛化能力较强。相比之下，哈萨克斯坦的 R^2 值（train: 0.9777, test: 0.8716）相对较低，尤其是在测试集上，说明其模型在新数据上的预测能力相对不足，可能存在过拟合或数据波动性较大的情况。


从 MAPE 指标来看，各国在训练集和测试集上的误差普遍较低，模型预测效果整体较好。日本（test: 0.0281）、新加坡（test: 0.0273）和越南（test:

0.0299) 在测试集上的 MAPE 均小于 3%，预测精度表现优异。中国的测试集 MAPE 为 0.1003，明显高于其他国家，虽然 R^2 仍维持较高水平 (0.9762)，但说明其模型在实际预测中存在一定误差，可能受不稳定因素影响较大。哈萨克斯坦的 MAPE 为 0.0742，在六个国家中仅次于中国，存在模型泛化性能偏弱的问题。

综合来看，各国模型整体拟合效果良好，但在泛化能力和预测精度方面存在一定差异，各国的基准模型有进一步优化的空间。

表 2 基准模型评估结果

国家	R^2		MAPE	
	train	test	train	test
中国	0.9951	0.9762	0.0543	0.1003
日本	0.999	0.9969	0.0158	0.0281
韩国	0.9994	0.9934	0.0252	0.0426
新加坡	0.9997	0.9973	0.0160	0.0273
哈萨克斯坦	0.9777	0.8716	0.0343	0.0742
越南	0.9968	0.9865	0.0137	0.0299






图 2 基准模型预测回归线组图

3. 模型优化


本文采用贝叶斯优化方法,通过 Tree-structured Parzen Estimator (TPE) 算法在 50 次迭代中搜索最优参数组合。具体而言,通过优化学习率 (learning_rate), 数的最大深度 (max_depth), 每棵树的特征采样比例 (colsample_bytree) 等关键超参数来优化基准模型。首先,定义了一个目标函数,基于当前超参数训练 XGBoost 模型,并计算测试集上的 R^2 值,将其负值作为优化目标进行最小化。接着,通过 Hyperopt 的 fmin 函数进行超参数搜索,设定最大评估次数为 50 次,超参数空间覆盖了合理范围。优化完成后,采用最优参

数组组合重新训练模型，并在测试集上评估最终模型的 R^2 值和 MAPE（平均绝对百分比误差），以验证优化效果。通过这种超参数优化，本文显著提升了模型在测试集上的预测性能，增强了模型的泛化能力。


以上操作均通过 Python 实现。

表 3 优化后模型的评估结果


国家	R^2		MAPE	
	train	test	train	test
中国	0.9951	0.9762	0.0543	0.1003
日本	0.999	0.9969	0.0158	0.0281
韩国	0.9994	0.9934	0.0252	0.0426
新加坡	0.9997	0.9973	0.0160	0.0273
哈萨克斯坦	0.9777	0.8716	0.0343	0.0742
越南	0.9968	0.9865	0.0137	0.0299




(1) 中国




(2) 日本




(3) 韩国



(4) 新加坡




(5) 哈萨克斯坦




(6) 越南


图 3 优化后模型的实际值和预测值




(1) 中国




(2) 日本




(3) 韩国



(4) 新加坡



(5) 哈萨克斯坦



(6) 越南

图 4 优化后模型的残差图

(三) XGBoost 模型预测的结果解释——基于 SHAP 模型

1. 原理介绍

在机器学习中，预测模型的可解释性可理解为向人们解释决策规则或决策依据的能力。构建适当的解释指标可帮助使用者了解模型的学习方式和预测能力，也可提供某个特征对模型的影响程度信息。基于此，使用者可根据解释结果调整模型结构，从而提高预测能力。

对于决策树模型，可根据每次节点划分带来的增益判断各特征变量的重要程度。在 XGBoost 模型中，基于所有树节点划分时特征使用次数总和、特征用于划分节点的增益以及选择某特征某种划分方式对样本的覆盖程度对特征的重要性排序。

为应对集成学习复杂度高、决策过程不透明的问题，Lundberg 和 Lee 于 2017 年提出 SHAP 值 (SHAPley Additive exPlanations) 作为衡量特征重要性的指标。

SHAP 值反映了特征对模型结果的贡献度，并可同时衡量局部解释能力和全局解释能力。对于某特征 i 的经典的 SHAP 值估计公式为

$$\varphi_i = \sum_{A \subseteq M \setminus \{i\}} \frac{|A|! (|M| - |A| - 1)!}{|M|!} [f_{A \cup \{i\}}(\mathbf{x}_{A \cup \{i\}}) - f_A(\mathbf{x}_A)] \quad (5)$$

其中， A 表示全部特征集合 M 的某一子集，该子集不包含特征 i 。 $f(\cdot)$ 表示输入特征向量 $\mathbf{x}$ 时对因变量的预测结果，在式 (5) 中分别由使用不包括特征 i 和包括特征 i 的子集训练模型得到。遍历所有符合条件的子集 A ，对应预测结果之差的加权平均即为特征 i 的 SHAP 值。

对于一个样本，计算特征 i 的 SHAP 值为

$$\varphi_i = \sum_{A \subseteq \{x_1, x_2, \dots, x_m\} \setminus \{x_i\}} \frac{|A|! (|m| - |A| - 1)!}{|m|!} [E(f(\mathbf{x}) | \mathbf{x}_{A \cup \{i\}}) - E(f(\mathbf{x}) | \mathbf{x}_A)] \quad (6)$$

基于特征向量 $\mathbf{x}$ 的预测结果以条件期望的形式给出。

样本特征的 SHAP 值满足式

$$y_m = y_{baseline} + \sum_{n=1}^N \varphi(t_{m,n}) \quad (7)$$

其中， $t_{m,n}$ 代表第 m 个样本的第 n 个特征， N 为特征总数， $\varphi(\cdot)$ 表示 SHAP 值。第 m 个样本的预测值 y_m 为所有样本预测值的均值 $y_{baseline}$ ，与该样本的所有特征的 SHAP 值之和。

SHAP 模型提供特征 i 对某一确定样本的重要性的衡量方式，即具有局部解释能力。对所有样本的特征 i 的 SHAP 值求绝对平均值，可评价该特征对模型的全局解释能力。

2. 特征重要性解释

本节使用 SHAP 模型解释中、日、韩、新加坡、越南、哈萨克斯坦六国人口死亡率模型的预测结果，评价各特征对预测结果的重要性，并分别计算日、韩五国模型的特征重要性与中国的相似度。图 5 为 SHAP 模型蜂群图，展示了每个样本在不同特征下的 SHAP 值。SHAP 值的绝对大小衡量模型中该国第 k 年 j 岁人口死亡率受到特征 i 的影响。图表显示，六国高年龄段人口死亡率普遍随保险密度增加而降低。当以人均医院床位占有量衡量的就医需求上升时，说明人口死亡率未得到改善。






图 5 各国人口死亡率 SHAP 蜂群组图


图 6 为 SHAP 模型特征重要性热图，展示特征对模型预测的影响方式。每个样本的 SHAP 值用颜色表示，红色代表正向影响，蓝色代表负向影响，颜色深浅代表影响强弱。矩阵上方的曲线表示预测结果。矩阵右侧的条形图代表该特征的重要性。图表显示，保险密度和医护水平对高年龄段人口死亡率的影响略强于其他模型指标。




(1) 中国




(2) 日本




(3) 韩国



(4) 哈萨克斯坦



(5) 新加坡



(6) 越南

图 6 各国 SHAP 模型特征重要性热图

3. 模型相似性度量

本节构造 SHAP 值分布相似度指标衡量特征在不同模型中的作用，为下节计算迁移学习模型权重提供参考。若某一特征在两个模型中具有相同或相近的 SHAP 值，则表明该特征在两种模型中起到的作用是相近的。在迁移学习的思想中，若两模型的 SHAP 值具有相近的分布，则证明两个领域的大部分知识互通，此时将基于源域训练得到的特征或模型迁移至目标域具有合理性。

本节参考唐義坤等（2025）的研究构造相似度指标：使用最大均值差异 (Maximum Mean Discrepancy, MMD) 衡量特征 i 的 SHAP 值在两模型间的分布相似性，并以该特征 SHAP 值的绝对值之和作为权重计算得出整体相似性。

特征 i 的 MMD 计算公式为式 (8)

$$V_i = MMD(S_i^{\#}, S_i^{\text{源}}) = \left(\frac{1}{n^2} \sum_{d=1}^n \sum_{d'=1}^n k(s_{i,d}^{\#}, s_{i,d'}^{\#}) - \frac{2}{nm} \sum_{d=1}^n \sum_{j=1}^m k(s_{i,d}^{\#}, s_{i,j}^{\text{源}}) + \frac{1}{m^2} \sum_{j=1}^m \sum_{j''=1}^m k(s_{i,j}^{\text{源}}, s_{i,j''}^{\text{源}}) \right)^{\frac{1}{2}} \quad (8)$$

其中， V_i 为特征 i 分布的最大均值差异， V_i 值越小，说明分布相似性越大。 n 、 m 分别为目标域（中国）和源域（其他五国）的样本数，本研究中均为 527 条。 $k(\cdot)$ 为核函数，可表示为

$$k(x, x') = \exp \left\{ -\frac{\|x - x'\|^2}{2\delta^2} \right\} \quad (9)$$

模型的整体 SHAP 值分布相似性可由下式 (10) 计算得出

$$\text{相似性} = \sum_{i=1}^K c_i V_i \quad (10)$$

其中， c_i 是特征值 i 的权重，为特征 i 的 SHAP 值绝对值之和在所有特征的 SHAP 值绝对值之和中的占比，即

$$c_i = \frac{\sum_{d=1}^n |s_{i,d}^{\#}|}{\sum_{i=1}^K \sum_{d=1}^n |s_{i,d}^{\#}|} \quad (11)$$

特征 i 的权重 c_i 越大，说明其对相似性度量的影响越大。

相似性计算结果如下表 4。结果显示，基于五国死亡率数据建立的预测模型中，特征重要性分布与中国死亡率预测模型大体保持一致。相比日、韩、新三国，越南和哈萨克斯坦预测模型中的特征重要性分布与中国差距略大，这是地理位置和经济发展水平共同作用的结果。

表 4 特征相似性结果

	源域				
	日本	韩国	新加坡	越南	哈萨克斯坦
中国 (目标域)	0.00056	0.00014	0.00036	0.0099	0.0081

（四）多人口死亡率迁移学习

1. 迁移学习原理

传统的机器学习模型建立在两个假设上：训练样本与测试样本满足独立同分布；必须有足够的可供学习的数据集以获得性能优秀的模型。然而实际应用中，这两点要求有时无法满足。一是原先数据的利用价值随时间推移降低，二是无标签数据不断涌现提高了数据标注成本。为解决这些问题，对迁移学习的研究是有必要的。

迁移学习是运用已存有的知识对不同但相关领域问题进行求解的一种新的机器学习方法。它放宽了传统机器学习中的两个基本假设，目的是迁移已有的知识来解决目标领域中仅有少量有标签样本数据甚至没有的学习问题。

迁移学习领域有以下重要概念：

- 域：包括特征空间和概率（本文指死亡率及影响死亡率的风险特征）
- 任务：包括标记空间和目标预测函数（本文指预测死亡率）
- 源域：提供用于迁移任务训练的数据（日韩新越哈五国的死亡率及风险特征）
- 目标域：提供迁移任务期望进行预测的数据集（中国的死亡率及风险特征）

迁移学习方法主要有样本权重迁移法、特征变换迁移法和模型预训练迁移法。样本权重迁移法通过设计权重的方式改变源域中样本的权重，提高有利于预测任务的实例权重，减小不利于任务的实例权重。特征变换迁移法使用最大均值差异度量距离，在优化目标中考虑边缘分布自适应和源域样本选择，目标是学习一个特征变化来减小正则化项。模型预训练迁移法在机器学习模型中嵌入迁移方法。本章使用样本权重迁移法优化模型权重，并使用最大均值差异进行验证。

2. 迁移学习集成框架

本节基于本章第（三）部分多国 XGBoost 死亡率预测模型建立多源域迁移学习集成框架。通过将合适的权重分配至单国死亡率预测模型，可实现源域信息筛选，且保持与目标域特征的相似性和最小化预测误差。模型权重可通过求解如下优化问题获得

$$\hat{\omega} = \arg \left(\min \sum_{q=1}^Q \frac{1}{Q} |y_{real}^q - y_{tr}^q| \right) \quad (12)$$

$$\text{s.t. } y_{tr}^q = \sum_{n=1}^N \omega_n y_{tr,n}^q + b \quad (13)$$

其中, y_{real}^q 为目标域(即中国)中第 q 个样本的实际死亡率, y_{tr}^q 为集成五国 XGBoost 模型的预测死亡率, 由式 (13) 计算得出。将中国高年龄段人口死亡率和年份、年龄、保险发展数据等特征分别输入源域(即日韩新越哈五国)死亡率预测模型, 输出基于五国人口学特征的中国人口死亡率预测值。 $y_{tr,n}^q$ 表示使用第 n 个源域模型对第 q 个样本的预测结果, ω_n 代表第 n 个源域模型预测值在最终输出结果的权重, 衡量模型贡献度。 b 为偏误项。通过线性规划求解优化问题, 寻找使预测死亡率与实际死亡率差距最小的源域分配权重。线性规划优化结果如下表 5。

表 5 源域权重分配结果

	权重/偏误项
新加坡	0.9305
越南	-0.0031
哈萨克斯坦	-0.0154
韩国	-1.0678
日本	1.9408
偏误项	0.0017
MAE	0.0037

图 7 为源域模型权重的可视化结果。图表显示, 日韩新三国对中国高年龄段人口死亡率预测贡献较大, 越南和哈萨克斯坦的贡献相对较小。这与上一章对样本特征相似度分布的比较结果一致。特征分布的距离越小, 模型相似度越大, 在加权预测模型中的贡献度高。日本、新加坡对目标域死亡率的预测产生正向作用, 另外三国则呈现负向作用。




图 7 源域模型权重示意图

使用集成五源域的人口死亡率预测模型预测中国人口死亡率，平均绝对误差为 0.0037，预测性能良好。下表 6 为各模型预测性能对比。结果显示，相比传统的使用单一数据源的机器学习模型，迁移学习能够更加高效的利用样本信息，提高预测精度。图 8 展示了中国人口死亡率预测值与实际值的差异。在低死亡率水平上，模型预测效果良好，在高死亡率水平上模型预测的绝对误差增大。

表 6 各模型预测性能对比图

模型[16]	MAE
随机森林	0.461
Adaboost	0.451
KNN	0.512
BP	0.535
Stacking 集成	0.417
迁移学习	0.003




图 8 中国人口死亡率预测值与实际值绝对误差结果图

五、结论

为解决中国高年龄段人口死亡率预测数据缺失的问题，本文基于迁移学习思想，构建了包含五国的集成学习框架。首先，在数据可得性的基础上，本文选择与中国经济发展水平相近或地理位置相邻的日本、韩国、新加坡、越南、哈萨克斯坦五个国家作为源域，并在保险、经济、医疗水平层面共计选取六项刻画高年龄段人口死亡率的风险特征。其次，本文基于各国人口死亡率分别建立单一国家的 XGBoost 预测模型，并使用 SHAP 值描述六项风险特征的贡献度分布，基于 MMD 计算分布相似度，初步判断各国死亡率对于中国人口死亡率的作用强弱。最后，本文基于单一国家死亡率预测模型结果，使用线性规划求解最优模型权重，即使中国预测死亡率与实际死亡率差异最小的各国死亡率权重。

将具有相似地理位置和经济状况的国家作为迁移学习的源域，求解最优模型权重，为预测目标域中国人口死亡率提供补充信息。模型预测效果良好。

由于人口统计发展较晚，我国人口学数据相对匮乏，为预测并对冲长寿风险带来挑战。本文创新性地将迁移学习思想引入人口死亡率预测，构建多人口死亡率预

测模型，使样本内外信息得到充分利用，为应对长寿风险提供新的思路。

本文可以从以下方面进一步拓展：

- （1）扩大迁移学习的源域死亡率和风险特征范围；
- （2）通过将数据细化增加样本容量提高机器学习模型的模型适配性和预测精度；
- （3）研究基于模型的迁移学习思路。

参考文献

- [1] 国家统计局. 第七次全国人口普查公报 (第五号) [EB/OL]. (2019-08-22) [2025-04-20].
https://www.stats.gov.cn/sj/tjgb/rkpcgb/qgrkpcgb/202302/t20230206_1902005.html
- [2] 国家卫生健康委. 2023 年我国卫生健康事业发展统计公报 [EB/OL]. (2024-08-29) [2025-04-20].
https://www.gov.cn/lianbo/bumen/202408/content_6971241.htm
- [3] 王晓军, 路倩. 高龄人口死亡率预测模型的比较与选择 [J]. 保险研究, 2019, (03): 82-102.
- [4] 王晓军, 路倩. 动态死亡率模型的研究进展 [J]. 应用概率统计, 2020, 36(04): 415-440.
- [5] 陶祥兴, 杨峥, 季彦颀. 基于机器学习的 Lee-Carter 模型死亡率预测方法研究 [J]. 人口与经济, 2022, (06): 47-57.
- [6] 段白鸽. 动态死亡率建模与长寿风险量化研究 [M]. 北京: 中国社会科学出版社, 2019.
- [7] 杨刚, 易艳萍, 孙超. 基于 AE-LSTM 改进模型的高龄人口死亡率预测 [J]. 数学理论与应用, 2022, 42(03): 100-113.
- [8] 肖鸿民, 李祥. 基于 Keras 的 LSTM 网络在死亡率预测的应用 [J]. 应用数学进展, 2021, 10(10): 3477-3486.
- [9] 于宏佳. 基于 Stacking 方法的中国人口死亡率预测 [D]. 江西财经大学, 2024.
- [10] 李芳芳. 基于模糊聚类 and Bi-GRU 的多人口死亡率模型研究 [D]. 西北师范大学, 2023.
- [11] 赵明, 王晓军. 我国人口死亡风险异质与混合模型研究 [J]. 统计研究, 2023, 40(03): 139-150.
- [12] 李昆骅. 跨国死亡率模型之建构及长寿债券定价之应用: 以 CBD 世代死亡率模型为架构 [D]. 台湾中央大学, 2014.
- [13] 唐義坤, 唐志远, 罗同桐, 等. 基于 XGBoost 与多源域迁移学习的贫资料地区负荷预测方法 [J/OL]. 现代电力, 1-11 [2025-04-20].

<https://doi.org/10.19725/j.cnki.1007-2322.2024.0038>.

- [14] 李志生, 刘恒甲. Lee-Carter 死亡率模型的估计与应用——基于中国人口数据的分析[J]. 中国人口科学, 2010, (03): 46-56+111.
- [15] 王晓军, 任文东. 有限数据下 Lee-Carter 模型在人口死亡率预测中的应用[J]. 统计研究, 2012, 29(06): 87-94.
- [16] 王振旭. 多影响因子下甘肃省人口死亡率预测模型比较研究[D]. 西北师范大学, 2024.
- [17] World Health Organization. World health statistics 2023: monitoring health for the SDGs, sustainable development goals[R/OL]. (2023-05-19) [2025-04-20].
<https://www.who.int/publications/i/item/9789240074323>
- [18] Cheplygina V , Bruijne D M , Pluim P J . Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis[J]. Medical Image Analysis, 2019, 54: 280-296.
- [19] Linda W , Qiu Z L , Alexander W . COVID-Net: a tailored deep convolutional neural network design for detection of COVID-19 cases from chest X-ray images. [J]. Scientific reports, 2020, 10(1): 19549-19549.
- [20] Pan J S , Yang Q . A Survey on Transfer Learning. [J]. IEEE Trans. Knowl. Data Eng., 2010, 22(10): 1345-1359.
- [21] Lee D R , Carter R L . Modeling and Forecasting U.S. Mortality[J]. Journal of the American Statistical Association, 2012, 87(419): 659-671.
- [22] Denuit M , Devolder P , Goderniaux A . Securitization of Longevity Risk: Pricing Survivor Bonds with Wang Transform in the Lee-Carter Framework[J]. The Journal of Risk and Insurance, 2007, 74(1): 87-113.
- [23] Wang L, Guo X, Shi H, et al. CRISP: A causal relationships-guided deep learning framework for advanced ICU mortality prediction[J]. BMC Med Inform Decis Mak, 2025, 25(1): 165.

- [24] Qiao Y , Wang C W , Zhu W. Machine learning in long-term mortality forecasting[J]. Geneva Pap Risk Insur Issues Pract, 2024, 49, 340 - 362.
- [25] Abdallah R , Abdelgaber S , Sayed H A . Leveraging AHP and transfer learning in machine learning for improved prediction of infectious disease outbreaks[J]. Sci Rep, 2024, 14, 32163.
- [26] Nalmpatian A , Heumann C , Alkaya L , et al. Transfer learning for mortality risk: A case study on the United Kingdom[DB/OL]. (2024-10-27) [2025-4-20].
<https://www.medrxiv.org/content/10.1101/2024.10.25.24316112v1>.
- [27] Cairns G J A , Blake D , Dowd K . A Two-Factor Model for Stochastic Mortality with Parameter Uncertainty: Theory and Calibration[J]. The Journal of Risk and Insurance, 2006, 73(4):687-718.
- [28] Domingos P . A few useful things to know about machine learning[J]. Communications of the ACM, 2012, 55(10):78-87.
- [29] Plat R . One-year Value-at-Risk for longevity and mortality[J]. Insurance Mathematics and Economics, 2011, 49(3):462-470.
- [30] Petar J , Chengwei Q , Hongjuan Z . Multi-population mortality modeling with Lévy processes[J]. Decisions in Economics and Finance, 2023, 46(2):583-609.
- [31] Chen H , MacMinn R , Sun T . Multi-population mortality models: A factor copula approach[J]. Insurance Mathematics and Economics, 2015, 63:135-146.
- [32] Kin K L , Bo W . Multipopulation mortality modelling and forecasting: the weighted multivariate functional principal component approaches[J]. Journal of Applied Statistics, 2023, 50(15):3177-3198.
- [33] Francesca P , Salvatore S . Locally-coherent multi-population mortality modelling via neural networks[J]. Decisions in Economics and Finance, 2022, 46(1):157-176.
- [34] Dimai M . Multi-population mortality modeling with economic,

environmental and lifestyle variables[J]. Quality & Quantity, 2024, 59(suppl 1):1-53.

附录

附表一 提交材料中主要文件及说明

类型	文件名	说明
死亡率数据集	China(mainland) mortality rates1996-2023 - 副本.csv	中国死亡率数据集
	Japan mortality rates1947-2023.csv	日本死亡率数据集
	Republic of Korea mortality rates2003-2023.csv	韩国死亡率数据集
	Singapore_mortality_rates.csv	新加坡死亡率数据集
	kazakhstan_mortality_rates.csv	哈萨克斯坦死亡率数据集
	vietnam_mortality_rates.csv	越南死亡率数据集
特征数据集	Medical_Staff_per_Capita (2).xlsx	每千人中的医生、护士和助产士数量数据集
	Healthcare_Expenditure_per_Capita.xlsx	人均医疗支出数据集
	Hospital_Beds_per_Capita.xlsx	每万人拥有的病床数数据集
	保险指标.xlsx	保险相关指标数据集
处理代码	Chinese_forecast(1).ipynb	计算 SHAP 值代码
	Japan&Korea-ssvd.ipynb	计算 SSVD 代码
	optim.ipynb	模型优化代码

说明：附表一仅列出了提交的支撑材料中主要的文件名及其说明，并未列全所有支撑材料，并非是本文实现过程中的所有文件。

附录二 优化部分代码展示

```
import pandas as pd
from numpy import *
import numpy as np
from scipy.optimize import linprog
import seaborn as sns
```

```

df = pd.read_csv('E:\比赛活动\学科竞赛\统计建模大赛\建模数据\ch.csv')
# 第一列是实际死亡率，后五列是预测死亡率
y = df.iloc[:, 0].values    # 实际死亡率
X = df.iloc[:, 1:6].values   # 五个预测模型

n_samples = X.shape[0]
n_features = X.shape[1]

# 线性规划求解 MAE 最小化
# 变量顺序: [w1, w2, w3, w4, w5, b, u1, u2, ..., un, v1, v2, ..., vn]
# 其中 u 是正偏差, v 是负偏差
# 目标函数系数 (最小化 sum(u_i + v_i)/n)
c = np.concatenate([
    np.zeros(n_features + 1),    # w 和 b 的系数为 0
    np.ones(n_samples) / n_samples,    # u 的系数
    np.ones(n_samples) / n_samples    # v 的系数
])

# 约束条件:  $Xw + b + u - v = y$ 
A_eq = np.zeros((n_samples, n_features + 1 + 2 * n_samples))
b_eq = y

for i in range(n_samples):
    #  $Xw + b + u_i - v_i = y_i$ 
    A_eq[i, :n_features] = X[i, :]    # X 的权重
    A_eq[i, n_features] = 1    # 截距 b
    A_eq[i, n_features + 1 + i] = 1    # u_i
    A_eq[i, n_features + 1 + n_samples + i] = -1    # v_i

```

```

# 变量边界
bounds = [(None, None)] * (n_features + 1) + [(0, None)] * (2 *
n_samples)

# 求解线性规划
result = linprog(c, A_eq=A_eq, b_eq=b_eq, bounds=bounds)

# 提取最优解
optimal_weights = result.x[:n_features]
optimal_intercept = result.x[n_features]

print("最优权重:", optimal_weights)
print("最优截距:", optimal_intercept)
print("最小 MAE:", result.fun)

# 可视化
# 权重分配图
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 5))
models = ['model_singapore', 'model_vietnan', 'model_ka',
'model_korea', 'model_japan']
plt.bar(models, optimal_weights, color='skyblue', edgecolor='black')
plt.axhline(0, color='gray', linestyle='--')
plt.title('Optimal Weights Allocation Across Models', pad=20)
plt.xlabel('Prediction Models')
plt.ylabel('Weight Value')
plt.grid(axis='y', alpha=0.3)

# 添加权重值标签

```

```

for i, w in enumerate(optimal_weights):
    plt.text(i, w/2, f' {w:.3f}', ha='center', va='center',
fontweight='bold')

plt.show()
# 实际和预测值对比
plt.figure(figsize=(8, 8))
predicted = X @ optimal_weights + optimal_intercept

plt.scatter(y, predicted, alpha=0.6, c='green')
plt.plot([y.min(), y.max()], [y.min(), y.max()], 'r--', lw=2)
plt.title(f'Actual vs Predicted Mortality (MAE = {result.fun:.4f})')
plt.xlabel('Actual Mortality Rate')
plt.ylabel('Weighted Prediction')
plt.grid(True, alpha=0.3)

# 添加残差线段
for yi, pi in zip(y, predicted):
    plt.plot([yi, yi], [yi, pi], 'gray', alpha=0.2)

plt.show()

```